#### YaDiff

#### Encore un outil de diff de binaires propagation de symboles

B. Amiaux, J. Bouetard, V. Comiti, F.Grelot, E.Renault, M. Tourneboeuf

Direction Générale de l'Armement / Maîtrise de l'Information

14 juin 2018



#### Introduction

- - Systèmes embarqués, binaires lourds
  - ► Temps d'exécution raisonnable



#### Introduction

- - Systèmes embarqués, binaires lourds
  - ► Temps d'exécution raisonnable
- © Propager le maximum d'information
  - ightharpoonup Version X.Y  $\rightarrow$  W.Z
  - ightharpoonup Linux  $\rightarrow$  Windows
  - ightharpoonup Lib ightharpoonup Exécutable



#### Introduction

- - Systèmes embarqués, binaires lourds
  - ► Temps d'exécution raisonnable
- © Propager le maximum d'information
  - $\triangleright$  Version X.Y  $\rightarrow$  W.Z
  - ightharpoonup Linux  $\rightarrow$  Windows
  - ightharpoonup Lib ightharpoonup Exécutable
- Supporter plusieurs architectures
  - ► ARM, x86, autre?
  - ▶ Options de compilation (optimisations, deboggage...)



### État de l'art

Logiciel	Entrée	License	Plugiciel IDA	Méthode	Autres Limitations
BinDiff	ASM	Privative	Oui	Signature des fonctions, basics blocs, séquences	
Diaphora	ASM	Libre	Oui	Signature des fonctions	Lent
Gorille	CFG	Privative	Non	Isomorphisme de sous-arbres	Compare seulement le CFG
SMIT	ASM	Privative	Non	Graphe d'appel	Ignore les fonctions isolées
TurboDiff	ASM	Libre	Oui	Signature des fonctions	Pas beaucoup d'heuristiques Incompatible avec Linux
PatchDiff	ASM	Libre	Oui	Signature des fonctions	
DarunGrin	nASM	Libre	Oui	Signature des fonctions	Pas facile à installer
BitShred	Octets	Privative	Non	N-gram	Pas cross-archi
Fcatalog	Octets	Libre	Oui	N-gram	Pas cross-archi



#### État de l'art

Logiciel	Entrée	License	Plugiciel IDA	Méthode	Autres Limitations
BinDiff	ASM	Privative	Oui	Signature des fonctions, basics blocs, séquences	
Diaphora	ASM	Libre	Oui	Signature des fonctions	Lent
Gorille	CFG	Privative	Non	Isomorphisme de sous-arbres	Compare seulement le CFG
SMIT	ASM	Privative	Non	Graphe d'appel	Ignore les fonctions isolées
TurboDiff	ASM	Libre	Oui	Signature des fonctions	Pas beaucoup d'heuristiques Incompatible avec Linux
PatchDiff	ASM	Libre	Oui	Signature des fonctions	•
DarunGrir	nASM	Libre	Oui	Signature des fonctions	Pas facile à installer
BitShred	Octets	Privative	Non	N-gram	Pas cross-archi
Fcatalog	Octets	Libre	Oui	N-gram	Pas cross-archi

- Pas de support des binaires lourds
- Pas de traitement de la sortie (autre qu'affichage)



### État de l'art

Logiciel	Entrée	License	Plugiciel IDA	Méthode	Autres Limitations
BinDiff	ASM	Privative	Oui	Signature des fonctions, basics blocs, séquences	
Diaphora	ASM	Libre	Oui	Signature des fonctions	Lent
Gorille	CFG	Privative	Non	Isomorphisme de sous-arbres	Compare seulement le CFG
SMIT	ASM	Privative	Non	Graphe d'appel	Ignore les fonctions isolées
TurboDiff	ASM	Libre	Oui	Signature des fonctions	Pas beaucoup d'heuristiques Incompatible avec Linux
PatchDiff	ASM	Libre	Oui	Signature des fonctions	
DarunGrir	nASM	Libre	Oui	Signature des fonctions	Pas facile à installer
BitShred	Octets	Privative	Non	N-gram	Pas cross-archi
Fcatalog	Octets	Libre	Oui	N-gram	Pas cross-archi

- Pas de support des binaires lourds
- Pas de traitement de la sortie (autre qu'affichage)



Notre solution : YaDiff

#### Contenu

Orchestrateur d'algorithmes : YaDiff "legacy"

Enchainement des algorithmes

Algorithme d'Intelligence Artificielle

Vecteur de caractéristiques

Apprentissage supervisé



#### Contenu

Orchestrateur d'algorithmes : YaDiff "legacy" Enchainement des algorithmes

Algorithme d'Intelligence Artificielle

Vecteur de caractéristiques

Apprentissage supervisé



#### Définitions

- Objet
  - ► Concept introduit dans notre chaine d'outils
  - ▶ Abstrait le type d'un élément (fonctions, blocs basiques, données)
- Bloc basique
  - ► Séquence d'instructions
- Fonction
  - Fonctionnalité
  - Implémentation
- Référence croisée
  - ► Lien logique entre les objets



### Signatures

- Associer un maximum d'objets de manière fiable
- Tolérant aux changements mineurs
- Temps d'exécution rapide



# mov r0, r1

add r2,

0x12345678


bl

Génération des signatures (Octets invariants)

#0x8



### Génération des signatures (Octets invariants)





### Génération des signatures (Octets invariants)


imm

register register mov register add

address

bl

### Génération des signatures (Octets invariants)





→ Condensat



### Algorithmes



### Algorithmes

- a Algo 1 : Association initiale
- a Algo 2 : Propagation par références croisées montantes
- Algo 3 : Propagation par références croisées descendantes





 $S_A$ 

 $S_F$ 

 $S_Z$ 

Binaire 1

 $S_K$ 

 $S_B$ 

$$S_B$$

$$S_E$$

$$egin{array}{c} S_W \ \hline S_A \ \hline S_G \ \hline \end{array}$$



Binaire 2





 $\overline{S_A}$ 

 $S_F$ 

 $S_Z$ 



 $S_X$ 

 $S_K$ 

Binaire 1

 $S_B$ 

 $S_{T}$ 

 $S_Z$ 

 $S_G$ 

 $S_A$ 

 $S_X$ 

Binaire 2

 $S_D$ 





 $\overline{S}_A$ 

 $|S_F|$ 

 $S_Z$ 

Binaire 1

 $S_X$ 

 $S_K$ 

 $S_B$ 

 $S_Z$ 

 $S_A$  $|S_G|$ 

 $S_X$ 

Binaire 2



 $S_X$ 

 $S_K$ 

 $S_B$ 

 $\overline{S_A}$ 

 $|S_F|$ 

 $S_Z$ 

Binaire 1



 $S_Z$ 

$$S_G$$

 $S_W$ 

Binaire 2



 $|S_D|$ 





 $S_A$ 

 $S_F$ 

 $S_Z$ 

Binaire 1

 $S_X$ 

 $S_K$ 

 $S_B$ 

 $egin{array}{c} S_A \ \hline S_E \ \hline S_G \ \hline \end{array}$ 

 $S_Z$ 

 $S_W$ 



 $|S_D|$ 

Binaire 2





 $S_A$ 

 $S_F$ 

 $S_Z$ 

Binaire 1

 $S_X$ 

 $S_K$ 

$$S_W$$

 $S_Z$ 

 $S_B$ 





Binaire 2









 $S_Z$ 

Binaire 1

 $S_X$ 

 $S_K$ 



 $S_Z$ 











 $S_X$ 

 $S_K$ 

 $\overline{S}_A$ 

 $S_Z$ 

Binaire 1

 $S_B$ 



 $S_Z$ 



 $S_W$ 

 $S_A$ 



Binaire 2





 $S_A$ 

 $S_Z$ 



 $S_X$ 

 $S_K$ 

Binaire 1


 $S_B$ 

 $S_Z$ 




 $S_W$ 






Binaire 2




























### Algo 2: Propagation montante






### Algo 2 : Propagation montante






### Algo 2: Propagation montante






### Algo 2: Propagation montante






### Algo 3: Propagation descendante






#### Algo 3: Propagation descendante






#### Algo 3: Propagation descendante





#### Algo 3: Propagation descendante





#### Enchainement des algorithmes

```
Fonction association():
    algo1_association_initiale()
    répéter
        algo2_propagation_montante()
        algo3_propagation_descendante()
    tant que nouvelles associations ajoutées
```



#### Résultats et applications

- Utilisable sur des gros binaires



#### Conclusion intermédiaire

- Répond à notre besoin
- Activement utilisé

#### Mais

- Pourrait obtenir un plus grand nombre de correspondances
- Ne supporte pas le multi-architecture
- Ne supporte pas les modifications importantes.



#### Contenu

Orchestrateur d'algorithmes : YaDiff "legacy" Enchainement des algorithmes

Algorithme d'Intelligence Artificielle Vecteur de caractéristiques Apprentissage supervisé




#### Vecteur de caractéristiques

- Instructions
- © Graphe d'appel




## Vecteur de caractéristiques







#### Vecteur de caractéristiques : Graphe de flot de contrôle




#### Vecteur de caractéristiques : Graphe de flot de contrôle




































BB Inst Boucle ... Xref JC READ ADD ... ... ... ... RE



```
BB Inst Boucle I... Xref JC READ ADD I.. I.. I.. RET
```




BB Inst Boucle ... Xref JC READ ADD ... ... ... ... RET





















































#### Distance entre vecteurs de caractéristiques

- Nombre de dimensions élevé
- Distances difficiles à définir
  - Quelques paramètres prépondérants
  - ► Certaines coordonnées sont liées
- Frontières floues



#### Définition

- Problème : étant donnés 2 vecteurs, représentent-ils la même fonction ?
- o Solution : un réseau de neurones
- Méthode : apprentissage supervisé
- Données d'entrée : un ensemble de vecteurs de fonctions connues



#### Corpus d'apprentissage

- Suffisamment fourni
- Facilement accessible
- Représentatif des données analysées



#### Corpus d'apprentissage

- Suffisamment fourni
- Facilement accessible
- Représentatif des données analysées

#### Dépôt Linux debian

- Wheezy & Jessie & Stretch
- 400k fichiers
- À faire évoluer une fois la démarche validée



### Corpus d'apprentissage

#### Entraînement vs Validation

- Objectif: détecter et éviter le sur-apprentissage
- Exclusion d'une partie du corpus de l'entraînement
- Tests sur cette partie
- libxhtml.so isolation de 3 binaires : nfsd.ko, cc1plus, libxhtml.so
  - environ 100k fonctions



© Vecteur de caractéristiques + Architecture



© Vecteur de caractéristiques + Architecture

#### Normalisation

- Pour chaque coordonnée, distribution :
  - non équirépartie
  - potentiellement non bornée
  - différente



© Vecteur de caractéristiques + Architecture

#### Normalisation

- Pour chaque coordonnée, distribution :
  - non équirépartie
  - potentiellement non bornée
  - différente



© Vecteur de caractéristiques + Architecture

#### Normalisation


- Pour chaque coordonnée, distribution :
  - non équirépartie
  - potentiellement non bornée
  - différente
- - ▶ de 0 à 1
  - maximise la variance



- Pour chaque vecteur, on conserve le nom du binaire et le nom de la fonction
- - ▶ Deux instances de fonctions sont sémantiquement identiques si les deux noms le sont (binaire+fonction)
  - ► Elles sont différentes sinon



# Conception de l'algorithme d'apprentissage automatique






# Apprentissage : fonctions étiquetées






### Apprentissage: + et -






## Apprentissage : réseau de projection






# Apprentissage : fonction de coût






# Apprentissage : fonction de coût






# Exploitation








# Exploitation







#### Résultats

# Comparaison d'une fonction avec les autres versions du même binaire

```
[LADDER][EVAL][0.00s][0] metric: 477.96982
                                                          / 32 bits): 933.70588 [17 sibblings], ranks in [6 - 133
Ladder for [876864] Infsd -- remove proc entry (Intel
    1079790][0.504<u>219574][0.005551429][nrsd -- atomic_dec_and</u> spin lock (Intel 80386 / 32 bits)|
     130338][0.752887033][0.009280259][nfsd -- __copy_from_user_ll (Intel 80386 / 32 bits)]
     533093][1.091241859][0.010920132][nfsd -- arm copy from user (ARM / 32 bits)]
    1079883][0.916691100][0.012009483][nfsd -- rt spin unlock (Intel 80386 / 32 bits)]
      129502][0.900925817][0.012271119][nfsd -- pv lock ops (Intel 80386 / 32 bits)]
     1079784][1.071697658][0.014492417][nfsd -- mutex lock (Intel 80386 / 32 bits)]
     943605][0.810944381][0.014661974][nfsd -- remove proc entry (ARM / 32 bits)]
      900646][1.071307493][0.015965492][nfsd -- csum partial (PowerPC or cisco 4500 / 32 bits)]
     1080171][0.892108948][0.016692763][nfsd
                                             -- rt up write (Intel 80386 / 32 bits)]
       70770][1.121043705][0.017173097][nfsd
                                             -- .rpc shutdown client (64-bit PowerPC or cisco 7500 / 64 bits)]
      71397][1.062122340][0.018237174][nfsd
                                             -- .gword addhex (64-bit PowerPC or cisco 7500 / 64 bits)]
                                             -- .wake up process (64-bit PowerPC or cisco 7500 / 64 bits)]
      71479][1.045865227][0.018292412][nfsd
                                             -- mutex do init (Intel 80386 / 32 bits)1
    1079991][0.979788133][0.018413384][nfsd
                                             -- .mnt want write file (64-bit PowerPC or cisco 7500 / 64 bits)]
       71277][1.046812001][0.018891755][nfsd
       706961[1.0445347091[0.0190419031[nfsd
                                               .mnt drop write file (64-bit PowerPC or cisco 7500 / 64 bits)]
      71573][1.073005776][0.019122235][nfsd
                                             -- .rpc unlink (64-bit PowerPC or cisco 7500 / 64 bits)]
      70543][1.063754186][0.019183440][nfsd
                                             -- .vfs rmdir (64-bit PowerPC or cisco 7500 / 64 bits)]
                                                .cache check (64-bit PowerPC or cisco 7500 / 64 bits)]
      71261][1.081320947][0.019579004][nfsd
      70625][1.072801285][0.019587792][nfsd
                                             -- .locks end grace (64-bit PowerPC or cisco 7500 / 64 bits)]
       71483 [1.093553917] [0.019799624] [nfsd -- .set posix acl (64-bit PowerPC or cisco 7500 / 64 bits)]
```



#### Résultats

### Comparaison d'une fonction avec les autres versions du même binaire

```
[LADDER][EVAL][120.00s][337744] metric: 114.80121
Ladder for [876864][nfsd -- remove_proc_entry (Intel 80386 / 32 bits)]: 8.00000 (17 sibblings), ranks in [2 - 39]/1345
    1079790][0.504219574][0.002655557][nfsd -- atomic dec and spin lock (Intel 80386 / 32 bits)]
     129536][1.134311844][0.002689022][nfsd -- set fs (Intel 80386 / 32 bits)]
ΪκΊΪ
     943605][0.810944381][0.002886003][nfsd -- remove proc entry (ARM / 32 bits)]
     9473061[2.0499496341[0.005552270][nfsd -- remove proc entry (PowerPC or cisco 4500 / 32 bits)]
     198972][5.925486433][0.005908569][nfsd -- remove proc entry (PowerPC or cisco 4500 / 32 bits)]
     781199 [3.443695263] [0.006057259] [nfsd -- remove proc entry (Intel 80386 / 32 bits)]
                                               remove proc entry (ARM / 32 bits)]
[X]
      52439][1.088887903][0.006791204][nfsd
     756194][5,790339007][0,010467720][nfsd
                                                remove proc entry (x86-64 / 64 bits)]
     781202][1.069555127][0.012558789][nfsd
                                                net generic.part.1 0 (Intel 80386 / 32 bits)]
     781584][1.068393730][0.013884161][nfsd
                                                net generic.part.3 (Intel 80386 / 32 bits)]
     781626][1.062813000][0.014329499][nfsd
                                                net generic.part.6 (Intel 80386 / 32 bits)]
     781423][1.087630798][0.016591001][nfsd
                                                net generic.part.1 (Intel 80386 / 32 bits)]
1[X]
     496018][1.709477965][0.017667634][nfsd
                                                remove proc entry (ARM / 32 bits)]
     372374][5.332226244][0.018103490][nfsd
                                                remove proc entry (Intel 80386 / 32 bits)]
     781276][1.069777819][0.020596625][nfsd
                                                net generic.part.1 1 (Intel 80386 / 32 bits)]
     1079771][1.176402809][0.022174485][nfsd
                                                call rcu (Intel 80386 / 32 bits)1
    1080196][5.569054868][0.022854714][nfsd
                                                remove proc entry (Intel 80386 / 32 bits)]
    1028625][4.934297144][0.022904934][nfsd
                                                remove proc entry (Intel 80386 / 32 bits)]
     533481][1.394036595][0.023260947][nfsd -- remove proc entry (ARM / 32 bits)]
     888361][2.356059694][0.029136794][nfsd --
                                                put zone device page (x86-64 / 64 bits)]
```



#### Résultats

#### Comparaison d'une fonction avec les autres versions du même binaire

```
[LADDER][EVAL][540.00s][1608032] metric: 45.34632
Ladder for [870864][nfsd -- remove proc entry (Intel 80386 / 32 bits)]: 0.00000 (17 sibblings), ranks in [0 - 16]/1345
     372374][5.332226244][0.001001099][nfsd -- remove proc entry (Intel 80386 / 32 bits)]
     781199][3.443695263][0.001294585][nfsd -- remove proc entry (Intel 80386 / 32 bits)]
      943605][0.810944381][0.002491688][nfsd -- remove proc entry (ARM / 32 bits)]
     1028625 [4.934297144] [0.002592712] [nfsd -- remove proc entry (Intel 80386 / 32 bits)]
      496018][1.709477965][0.003801425][nfsd -- remove proc entry (ARM / 32 bits)]
     1080196][5.569054868][0.004284129][nfsd -- remove proc entry (Intel 80386 / 32 bits)]
ΓXΊ
      52439][1.088887903][0.007239995][nfsd -- remove proc entry (ARM / 32 bits)]
                                             -- remove proc entry (PowerPC or cisco 4500 / 32 bits)]
      947306][2.049949634][0.009259175][nfsd
      269148][6.218058688][0.012043204][nfsd
                                             -- remove proc entry (x86-64 / 64 bits)]
     888060][5.620438449][0.013195468][nfsd
                                             -- remove proc entry (x86-64 / 64 bits)]
[X]
     676419][3.700961476][0.015630072][nfsd
                                             -- remove proc entry (ARM / 32 bits)]
ΪΪΧΊ
     186528][5.473922680][0.015866069][nfsd
                                                remove proc entry (Intel 80386 / 32 bits)]
                                                remove proc entry (PowerPC or cisco 4500 / 32 bits)]
[X][
      198972][5.925486433][0.017689172][nfsd
ĪſXĪ
      533481][1.394036595][0.022609925][nfsd
                                             -- remove proc entry (ARM / 32 bits)]
[X]
      900676][7.413600353][0.024682559][nfsd
                                                remove proc entry (PowerPC or cisco 4500 / 32 bits)]
īrxī
      130054][6.355939734][0.031016290][nfsd
                                                remove proc entry (Intel 80386 / 32 bits)]
                                             -- remove proc entry (x86-64 / 64 bits)]
      756194][5.790339007][0.044317406][nfsd
      781584][1.068393730][0.044801235][nfsd
                                                net generic.part.3 (Intel 80386 / 32 bits)]
      877037][1.064036173][0.047644138][nfsd -- __be32_to_cpup.isra.7 (Intel 80386 / 32 bits)]
      129536][1.134311844][0.086903065][nfsd -- set fs (Intel 80386 / 32 bits)]
```



#### Total

```
Fonction association():
   algo1 apprentissage automatique()
   algo4 associations initiales()
   répéter
        algo2 propagation montante()
        algo3 propagation descendante()
        pour chaque association de la liste faire
            si score ia élevé
                ajouter association à la liste point de pivot
    tant que nouvelles associations ajoutées
```



#### Travaux restants

- Vecteurs : ajouter d'autres paramètres discriminants
- Apprentissage : Gradient Boosting, . . .
- Sortie: "function dating"



### Conclusion

- Fonctionne
- Utilisé
- IA prometteur

NOTE : pour en savoir plus, lire le papier



### One more thing

- https://github.com/DGA-MI-SSI/YaCo
- GPLv3

NOTE: pour en savoir plus, lire le papier



# Questions?

 $\ensuremath{@}$  Rendez-vous ce soir pour en discuter



### Améliorations

- Intégrer l'IA
  - ▶ Dans la version open source sur Github

